

中国电机工程学报  
*Proceedings of the CSEE*  
ISSN 0258-8013, CN 11-2107/TM

## 《中国电机工程学报》网络首发论文

题目：基于尾流关联的动态超图风电功率超短期预测方法  
作者：钟吴君，李培强，涂春鸣  
网络首发日期：2024-05-28  
引用格式：钟吴君，李培强，涂春鸣. 基于尾流关联的动态超图风电功率超短期预测方法[J/OL]. 中国电机工程学报.  
<https://link.cnki.net/urlid/11.2107.tm.20240528.0953.003>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

# 基于尾流关联的动态超图风电功率超短期预测方法

钟吴君，李培强，涂春鸣

(湖南大学电气与信息工程学院 湖南省 长沙市 410082)

## Dynamic Hypergraph Wind Power Ultra Short Term Prediction Method Based on Wake Correlation

ZHONG Wujun<sup>1</sup>, LI Peiqiang<sup>1</sup>, TU Chunming<sup>1</sup>

(1. College of Electrical and Information Engineering, Hunan University, Changsha 410082, Hunan Province, China)

**ABSTRACT:** Accurate wind power prediction is of great practical significance for the safe and stable operation of the power system. Due to factors such as wake effects, there are complex correlation characteristics between wind turbines in a wind farm. Existing research has overlooked the dynamic changes in spatiotemporal correlation characteristics, and traditional graph based binary relationship representation methods are also difficult to accurately characterize the complex and diverse spatiotemporal relationships between wind turbines, resulting in difficulty in accurately capturing the spatiotemporal characteristics between fans. Considering the poor solvability of deep learning models and the impact of wake effects on wind power, this paper proposes a dynamic hypergraph wind power ultra short term prediction method based on wake correlation. Firstly, each wind turbine is regarded as a node, with the historical power of each wind turbine as the feature input, and the spatial position and complex relationships of the wind turbine as the hyperedges. A dynamic hypergraph representation structure of the wind turbine is constructed along the time dimension. Then, combining the wind direction data and wind turbine information at each moment, based on the Jensen wake model principle, a dynamic hypergraph based on wake correlation is constructed in the form of ray method. On this basis, for the special data structure of dynamic hypergraphs, a spatiotemporal aggregation feature extraction module based on dynamic hypergraph convolution and a spatiotemporal feature fitting module based on BiLSTM are constructed to extract dynamic spatiotemporal features and achieve accurate prediction. Finally, experimental analysis is

conducted based on real wind power data to verify the superiority of this method from multiple dimensions.

**KEY WORDS :** wind power prediction; hypergraph; dynamic characteristics; spatio-temporal characteristics; wake effect; dynamic hypergraph convolution

**摘要：**精准的风电功率预测对于电力系统安全稳定运行具有十分重要的现实意义。受到尾流效应等因素影响，风电场内各风机之间存在着复杂的关联特性。现有研究忽略了时空关联特性的动态变化过程，传统图结构的二元关系表示方法也难以精确的表征风电机组间复杂多元的时空关系，导致风机间的时空特征难以精确捕捉。同时考虑到深度学习模型可解性差的问题与尾流效应对风电功率的影响，本文提出一种基于尾流关联的动态超图风电功率超短期预测方法。首先，将各风机视为节点，各风机历史功率作为特征输入，风电机组的空间位置和多元复杂关系作为超边，沿着时间维度构建风电机组动态超图表示结构。然后，结合每个时刻的风向数据与风机信息，根据 Jensen 尾流模型原理，以射线法的形式构建基于尾流关联的动态超图。在此基础上，针对动态超图的特殊数据结构，构建基于动态超图卷积的时空聚合特征提取模块与 BiLSTM 的时空特征拟合模块，提取动态时空特征并实现精准预测，最后，基于真实风电数据进行实验分析，从多维度验证该方法的优越性。

**关键词：**风功率预测；超图；动态特性；时空特性；尾流效应；动态超图卷积

## 0 引言

随着我国双碳政策的推行，截至 2022 年，我国风力发电装机容量已经达到 3.7 亿千瓦<sup>[1]</sup>，风能作为清洁能源，已经成为我国能源结构中的重要一环<sup>[2]</sup>。但气象的不确定性会导致风电出力呈现随机性与波动性的特点，这会对电网的安全

基金项目：国家重点研发计划项目（2021YFB2601504）、国家自然科学基金项目（52377097）。

National Key R&D Program Project (2021YFB2601504), National Natural Science Foundation Project (52377097).

稳定运行造成巨大影响。精确的风电功率预测,可以减轻调度压力、降低风电站考核成本、对电网的规划端和决策端均具有重大现实意义<sup>[3]</sup>。

长期以来,风电功率预测领域一直是研究热点,已取得了众多成果。研究者们普遍使用的方法主要分为物理方法、统计学方法和机器学习方法,物理方法<sup>[4-6]</sup>主要是利用物理原理和风力发电机的工作机制来估计未来的风能产生的功率。这种方法依赖于数学模型和大气科学的知识,可解释性强,但需要建立复杂的大规模模型,导致计算成本较高,难以实现现场部署。统计学方法主要有差分自回归移动平均模型<sup>[7]</sup>、非参数回归<sup>[8]</sup>、马尔可夫链模型<sup>[9]</sup>等,往往是通过滑动窗口进行数据拟合,具备模型简单、计算快速和不需要海量数据支撑等优点,但难以提取隐含的高维特征,预测性能不佳。

随着智能电网技术的推进,数据采集与监视控制系统(Supervisory Control And Data Acquisition, SCADA)、工程生产管理系统(Power Production Management, PMS)等信息采集技术的发展,为需要大规模数据集的深度学习方法提供优质可靠的数据基础,使其逐渐成为主流:传统的深度学习模型如长短期记忆网络(Long Short-term Memory, LSTM)<sup>[10]</sup>、门控循环单元(Gated Recurrent Unit, GRU)<sup>[11]</sup>、极端梯度提升机(eXtreme Gradient Boosting, XGBoost)<sup>[12]</sup>等在时序预测任务之中取得良好的效果,但面对随机性、波动性较大的风电时间序列时,单一深度学习模型对于复杂数据特征的捕捉能力较弱,不适宜应用于数据维度较大的问题。研究者们便将深度学习模型与特征工程<sup>[13-14]</sup>、信号分解<sup>[15-16]</sup>、误差补偿<sup>[17-18]</sup>等方法相结合,提升预测性能。但上述基础方法忽略了风电场内部风机之间的内在时空关系,使得模型提升幅度有限。

相邻风机之间由于空间位置临近,受到尾流效应等因素的影响<sup>[19]</sup>,各个时刻出力会存在动态关联的变化。各风机之间具有空间相关性,而单机自身在时间维度上具有时间相关性,意味着风机的历史功率和临近风机的实时出力存在着关联关系,这就是作者所描述时空相关性。为了更好地刻画这种时空关系,图表示结构的技术开始进入人们视野。文献[20]利用空间距离定义节点

之间的关系,构建静态图结构,使用时空注意力机制与图卷积网络(Graph Convolutional Network, GCN)提取其时空特征并预测。文献[21]使用格兰杰因果关系定义空间关系构建图结构,并将多尺度时间卷积网络嵌入GCN之中,从而提升预测精度;文献[22]在利用空间位置建立静态图结构的基础上使用图注意力(Graph Attention, GAT)实现特征提取,之后,将特征分别放入GRU和时间卷积网络中进行预测,最后使用深度确定性策略梯度算法对两次预测结果进行动态优化。上述文献在利用静态的图结构对风电功率数据建模取得一定成果,但天气的变化会使得风机之间的时空关系会沿着时间维度动态演化,传统的静态图结构无法详细描述此动态过程<sup>[23]</sup>。

为了更精准的模拟实际情况,研究者将目光投向动态图结构,文献[24]计算风电功率的互易系数,并分别构建风速和功率的时空相关矩阵,来描述相邻风场之间的动态时空信息;文献[25]在光伏预测领域使用动态机制,利用相关性指标和数据驱动方法对经变分模态分解所求得各模态构建动态图结构,并利用GCN实现预测功能;文献[26]利用最大信息系数构建动态图结构,实现对风电机组输入变量之间的非线性特征进行动态描述。虽然上述研究运用动态图表示结构能在捕捉时间维度上的特征和建模演化过程上有显著的优点,但忽视了实际的风机关系是多元复杂的<sup>[23]</sup>,这也会限制时空特征的精准捕捉和最终预测精度提升,且使用关联性指标与地理位置信息来建模图或动态图结构,无法使预测模型摆脱深度学习模型可解释性不强的限制。

综上,作者总结了现有风电功率预测领域应用图或动态图结构的预测方法普遍存在的四个问题:(1)尽管很多方法使用图或动态图结构在风功率预测领域彰显了较好的性能,但在表达超越二元关系的复杂结构时会存在着局限性,实际情况下,由于尾流效应等因素影响,风机间关系是多元相互作用的,系统中可能存在丰富的非成对结构关系。而涉及到共享相似属性的多个节点时,两两关系建模是低效的。这种关系描述的缺失限制了模型整体的性能,因此,图或动态图结构难以对复杂的时空交互关系进行深层次的建模。(2)静态的图结构无法完整地描述实际过



程,受到天气因素影响,风电出力动态变化,各风机间的联系同时发生动态变化,以恒定的关联关系去考虑,无法反映出力的短时变化,难以提升精度。(3)若利用关联性指标或者地理上的相对距离构建风电机组之间的关联关系时,仅能统计学的角度分析说明影响,并未深入研究造成影响的物理机理,无法摆脱神经网络模型可解释性不强的限制,难以深层挖掘节点特征、有效表征节点复杂性。(4)对图或动态图结构的数据进行特征提取的过程中,非欧数据结构使得传统卷积神经网络(Convolutional Neural Network, CNN)等基础网络很难适应,而且时空特征在时间维度上与空间维度上都具有依赖性,因此需针对数据结构设计网络架构从时间空间两个维度同时挖掘。

针对上述4大问题,本文提出基于尾流关联的动态超图风电功率超短期预测方法,首次将超图表示结构应用于新能源预测领域,突破了传统图表示结构仅能描述二元关系的限制,更好地表述了风电机组之间复杂的多元关系;同时,作者在超图基础上增加动态机制,解决了传统静态图结构无法细致描述风电机组间动态时空关联特性的问题,使得超图表示结构能够更为有效的表征时间、空间双维度的高阶特征;在此基础上,创造性地针对风力发电场景并结合 Jensen 尾流效应模型提出基于尾流关联的动态超图构建方法,赋予深度学习模型物理机理层面的内涵,弥补深度学习模型可解释性较低的缺陷;最后,针对动态超图特殊的数据结构构建基于动态超图卷积(Dynamic Hypergraph Convolutional Network, DHGCN)的时空聚合特征提取模块(Spatio-Temporal Aggregation Feature Extraction Module, STAFEM),深入挖掘风电机组动态时空关联特征,并利用双向长短时记忆网络(Bidirectional Long Short-Term Memory, BiLSTM)实现风电功率精确预测,从而为新能源并网提供数据源侧的支撑。

## 1 风电动态时空关联特性分析

风电场内各机组由于空间距离较近,在地形气象方面具有一定的相似性,上游机组的尾流效应也会影响风电场内各机组分布,这会导致风机之间的空间关联特性不是简单的两两关系<sup>[19,23]</sup>,图1展示了天气混沌特性与多机组尾流效应的交

互作用下的风功率行为模式。




图1 风功率行为模式

Fig.1 Wind power behavior model

如图1所示,相邻风机间不仅具有时间序列上连续的特征,而且在空间维度上也是高度相关的。其中,空间上的高相关性由区域内近似的气象条件导致。然而,这种高相关性并不意味着全部风机的行为模型均相似,而是只有部分风机的功率变化趋势相近,且变化幅度由风机间的尾流效应决定。图2描述了相邻时刻的风机间的尾流影响。

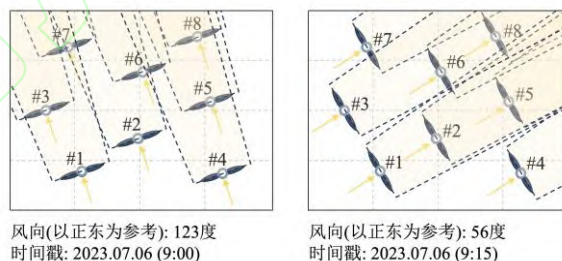


图2 不同时刻风机尾流效应影响情况

Fig.2 Impact of wind turbine wake effect at different times

如图2所示,当上行风机较多时,可显著削弱下行风机所接收的风能。这种因削弱风能而构成的关联呈现出“嵌套式”的多元性,即,除多台风机同时受一台上行风机的外部尾流影响外,受扰风机内部也因尾流存在关联。一旦风向改变,尾流影响的受体和程度也随之变化。总体上,风机内的尾流影响将由多台风机所决定,且处于不断重构的状态,表现了极高的多元特性和动态特性。因此,可以考虑引入相邻机组的功率数据与风机间的尾流效应情况以提高预测精度。

## 2 基于尾流关联的动态超图风功率超短期预测方法

由上一章分析,风电集群在运行时,除受到外界气象状况影响外,内部各风机间也存在交互影响。这导致集群内部的风机出力在空间上表现出了趋同性以及相似性,但又因所处空间位置的不同而产生差异,如果可以将集群空间信息纳入现有的“气象-风功率”预测体系<sup>[27]</sup>,则可增补空间尺度上的风功率态势模型,与时序预测模型共同感知风电集群的时空特性,进而实现大数据背景下,深度学习模型与物理模型的深度耦合。在集群内部的存在多种复杂物理过程,其中风机尾流效应可综合表现风机的地理位置与气象影响。将尾流效应接入预测模型,可实现同步学习地理及气象变化对风功率的影响模式。

然而,现有的如 BiLSTM 的常规预测模型无法理解空间信息,强行输入该类信息并不会对模型性能提升有实质性的提升。随着由图神经网络(Graph Neural Network, GNN)衍生的 GCN 逐步兴起,为探究时序问题的空间相关性提供了强大工具。以集群内风机为研究实体构成图中顶点,之间的空间关联为边连接各风机,顶点与边构成图输入 GCN 提取风机间的空间特征。但 GCN 并不能与风机集群状态良好匹配,原因在于两点(1) GCN 的构建基础为静态图,这种图表示结构只允许两个风机产生邻接关联,无法描述群体的空间尾流关联行为;(2)风向呈现出强烈随机性,使得尾流关联表现出高动态,所对应图结构不唯一,静态图无法描述这种异构图变化。

为了表征集群内风机关联的多元性以及动态性需要引入一种全新的关联分析方法。近年来,随着超图神经网络的兴起,超图<sup>[28-29]</sup>逐步活跃于交通流量预测<sup>[30]</sup>、生物医学<sup>[31]</sup>、计算机视觉<sup>[32-33]</sup>等领域。而动态超图在普通超图基础上进行外拓,结合了超图以及动态图的优势,形式不再局限于两个实体间的联系,同时随实体关联变化,图结构会相应地异构化,极大提升了关联描述能力,和动态描述能力。因此,动态超图可全面契合表征集群内风机关联多元性以及动态性的要求。对此,本文以风电集群内风机的尾流关联构建风功率动态超图,并构造 STAFEM 挖掘其中的时空特性,利用 BiLSTM 拟合时空特征,实

现预测功能。

### 2.1 风电机组动态超图表示结构

风机之间在空间维度具有很强的空间相关性,不同的空间结构建模方式对风电机组预测会产生较大影响。受到尾流效应与复杂混沌天气状态的影响,风电机组间具有非二元联系的复杂关系<sup>[23]</sup>,若用图表示结构以静态二元关系简单表征,则会丢失风机间的高阶关系,为了解决这一局限性,作者使用风电机组的动态超图结构的表示方法。图 3 为超图与普通图的对比。

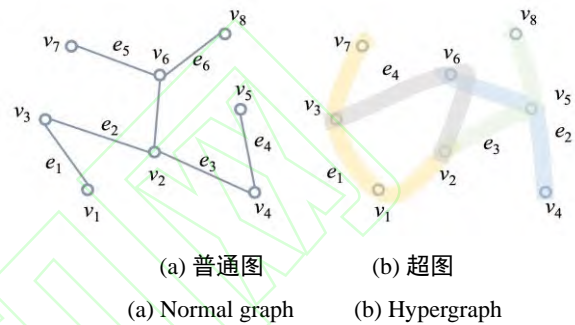


图 3 普通图与超图结构对比

Fig. 3 Comparison of normal graph and hypergraph structures

如图 3 所示,形式上,传统图是将数据点映射到节点,将两个点之间的连接或者相关性映射到边,无法表征风机间的多元关系。而超图在普通图的基础上进行高维非线性外拓,可更准确地描述风机间的多元空间关联。通过简化顶点连接形式,以刻画更加丰富的信息,充分挖掘各台风机之间的高阶关系交互,实现更高维的关联建模能力,且不存在顶点信息丢失的情况。以矩阵形式表征超图  $G$  中复杂结构信息:

$$\begin{cases} G = \{V, E, H, X, W\} \\ V = \{v_1, \dots, v_n\} \\ E = \{e_1, \dots, e_m\} \end{cases} \quad (1)$$

其中,  $V$  为顶点集,包含  $G$  中的  $n$  个顶点;  $E$  为超边集,包含  $G$  中的  $m$  个超边;  $H$  为二值关联矩阵,包含了  $G$  中顶点与超边的连接信息,如果  $H_{ij} = 1$ ,则表示顶点  $v_i$  与超边  $e_j$  相连,如果,  $H_{ij} = 0$  则表示二者没有连接关系;  $X$  和  $W$  分别为超边特征矩阵及顶点特征矩阵,分别表示了输入的超边及顶点上的特征值信息。

静态超图结构在揭示顶点之间的复杂关系方面受到限制:如果输入的超图结构固定,则节点之间的关系是固定,而现实情况是在风向的变化

将导致上游风机和下游风机的反复调换，风机间的尾流影响也在动态变化，会导致超图结构变化。节点之间的关系随着时间推移变化，因此静态超图无法实时描述这种情况。为此，本文为超图结构加入动态机制以解决该问题，克服了固定输入的静态超图限制。图 4 展示了动态超图结构。

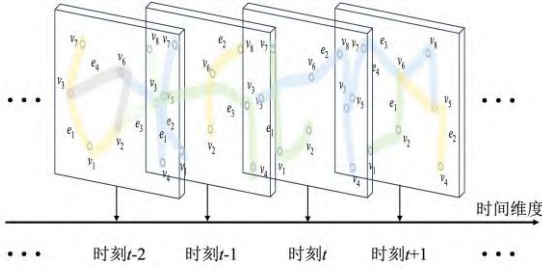


图 4 动态超图结构

Fig.4 Structure of dynamic hypergraph

如图 4 所示，动态超图是由一系列异质静态超图沿时间维度串联而成的离散图集合。不同时刻的超图构成不一，各时刻的超图结构对应着多元关联的时序演进。随图的深度不断增加，每个本层图的顶点信息都会与上层图中对应顶点的信息不断聚合。时序靠后的图将携带大量顶点的信息，甚至包含全图信息。一个历时  $T$  的动态超图  $G^D$  可定义为：

$$G^D = (G^1, \dots, G^t, \dots, G^T) \quad (2)$$

其中， $t$  时刻的  $G^t$  被定义为：

$$\begin{cases} G^t = \{V^t, E^t, H^t, X^t, W^t\} \\ V = \{v_1^t, \dots, v_n^t\} \\ E = \{e_1^t, \dots, e_m^t\} \end{cases} \quad (3)$$

本文以风电集群的内部风机为顶点、以风机间尾流的交互影响为动态超边建立准则，结合实际风向构建动态超图（具体构建方法详见 2.2）。所构建的动态超图物理意义表示为特定方向下，各风机产生尾流对其他风机的影响。

## 2.2 基于尾流关联的动态超图构建

风力发电机接收到较低速度和湍流较大的风，从而降低了它们的输出功率。这种降低的风速会导致发电机叶片受到较少的驱动力，从而减少了发电机的发电能力，尾流效应使风电场的风速和功率分布变得更加复杂<sup>[34]</sup>。

风力发电是指风机捕获风动能，再转化为机

械能以及电能的过程。其过程满足如下表达式：

$$P = \frac{1}{2} \rho_{\text{air}} V^3 \pi R^2 C_p \quad (4)$$

其中， $P$  为输出的风电功率； $\rho_{\text{air}}$  为空气密度； $V$  为风速； $R$  为风轮扫风面的半径； $C_p$  为功率系数。

由式 (4) 可知，风速与风功率高度关联，是影响风机的功率输出主要影响因素。风速不仅随决定于外界环境，还受尾流效应的影响。尾流效应在风机空间排布与受风风向共同作用下产生：风向上游风机对下游风机形成遮挡。使下游风机所接受到的风速有所衰减，间接导致风功率的损失。在集群实际运行时，内部尾流效应错综复杂，每台风机都有可能受到多台风机的尾流影响，损失功率陡增，使得该部分不可忽略。

常规关联关系描述方法，通过皮尔逊分析等关联性指标建立功率序列间的线型关联。但该方法是一种单纯的数据分析，无法描述的集群尾流物理过程，且关联性指标的研究对象为序列，无法实现分辨率为时刻的高动态关联关系构建。

因此，本文使用 Jensen 尾流模型描述尾流扩散情况，并由此构建基于尾流关联的动态超图。该方法将空间地理信息与气象影响接入预测模型，同步分析时序因果特征及空间因果特征，将物理过程与统计模型有机衔接起来，赋予深度学习模型物理意义，增强可解释性，更好地描述集群内的复杂多元关系。由于同风电场的风机安装海拔相近，故不考虑海拔对尾流的影响。

### 2.2.1 Jensen 尾流模型

Jensen 尾流模型<sup>[35]</sup>（下文称为 J-model）以线性模型大幅简化尾流传播过程，其俯视角度传播过程示意图如图 5。




图 5 Jensen 尾流模型示意图

Fig. 5 Schematic diagram of Jensen wake model

如图 5 所示，俯视角度下，风在穿过上游风机后，在后方留下一个梯形的风力衰减区，且该



区域以梯形腰线向下游辐射，同时伴随着区域面积的逐步增长。

J-model 以穿过风机前后的风质量守恒为理论基础，结合尾流半径呈线性增长的假设，定义了上游风机后  $x$  处风机输入风速的计算过程：

$$u = u_0 \left( 1 - \left( 1 - \sqrt{1 - C_T} \right) \left( \frac{r_0}{r_0 + kx} \right)^2 \right) \quad (5)$$

其中， $u_0$  为风机输入风速； $C_T$  为风机的推力系数； $r_0$  为风机叶轮长度； $k$  为尾流衰减因素，陆上风电场取值 0.075。由式 (5) 知，随着距离的增长，尾流效应逐步减弱。然而，集群内部的风机排布紧密，尾流效应的影响显著。所以后续利用尾流关联和构建超图时不考虑距离层面的影响，而是将处于同一尾流扩散范围内的风机划归至一条超边。

### 2.2.2 动态超图构建过程

引入尾流效应的目的是为了描述尾流影响下的集群内部功率变化规律。本文认为该规律可描述为一种关联形式。即某一台风机受另外一台风的尾流影响，则这两台风机存在尾流关联，且这种关联模式可拓展至更多风机的尾流影响。由于本文的核心意图在于描述完整的风机间尾流影响，充分刻画因尾流效应建立的关联行为，所以不考虑距离对尾流衰减的影响。本文定义了超边构建准则：在同一上游风机尾流扩散区域内的全部下游风机处于同一超边，如果某一机组受到多台风机尾流效应影响，则该风机同时隶属多条超边。图 6 展示了基于超边构建准则的超图构建过程。




图 6 本文动态超边构建方法实例

Fig. 6 An example of dynamic hyperedge construction method in this paper

如图 6 所示，#5、#6 和 #8 同时处于 #4 的尾流扩散区域内，则以 #5、#6、#8、#4 为顶点构建超边；同理，#2、#6、#7 位于同一条超边上，#1、#3、#7 位于同一条超边上。基于上述的超边构建准则，以集群内风机为超图顶点，构建基于尾流关联的动态超图结构，如图 7 所示，

本文所提出超图模型构建过程包含 5 个子过程：风机坐标读入与转换、读取风向确定受风顺序、放置尾流辐射区域、超边选定及合并，整合超边构成动态超图，详细构建过程见附录 A。

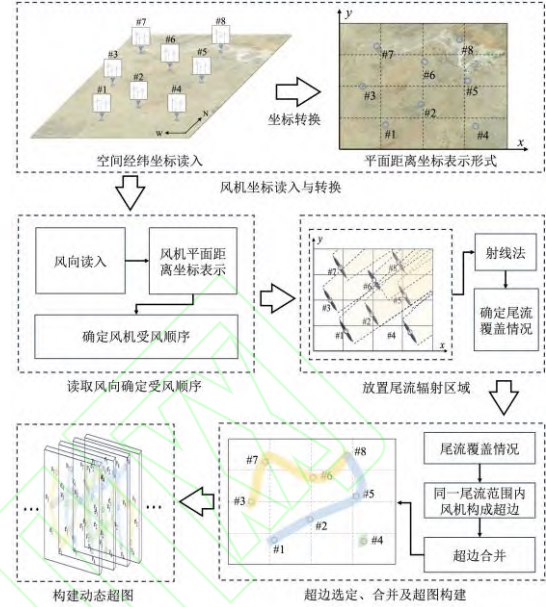


图 7 基于尾流关联的动态超图构建过程

Fig. 7 Construction process of dynamic hypergraph based on wake association

### 2.3 基于动态超图卷积的时空聚合特征提取模块

传统风功率预测关注的是短序列的时序特征，无法与相关同质序列建立有效联系，随着时间跨度增加，数据的时序特征出现明显变化，预测会出现明显失准。为此，本文考虑融入可反映集群内的时空特征参与预测，所以本文利用尾流关联实时描述风电机群内部的动态联系，并在 2.2 中构建了基于尾流关联的动态超图表示结构，通过融入基于动态尾流关联的集群时空特征，将物理过程与深度学习模型相结合，以增强预测模型的风力发电描述能力。其中，集群时空特征是由尾流效应串联起的多台风机间交互关联，表示了空间排布以及气象影响下的集群内部功率变化情况。因此，这种时空特征并不能完全代表功率的时序变化。所以参考常规的风功率预测方法，在已构建动态超图的信息结构上，融入风功率序列的时序特征。如此引发了两个问题：

(1) 现有的超图卷积 (Hypergraph Convolutional Network, HGCN) 针对静态超图定制，难以适应现实场景中的信息动态演化。(2) 基于尾流关联的时空特征与风功率时序特征无法通过单

一特征提取模型处理。对此，本文结合 DHGCN 及 CNN 提出 STAFEM。图 8 展示了 STAFEM 的数据处理的过程。




图 8 STAFEM 的数据处理过程

Fig. 8 Data processing process of STAFEM

如图 8 所示，STAFEM 主体为 CNN 时序特征提取模块以及 DHGCN 时空特征提取模块。其中，前者利用滑动窗口循环输入风功率序列，利用一维 CNN 从数据结构上简化序列；后者滑动输入各时刻超图结构，通过 DHGCN 对输入到其中的单个时间步超图进行信息聚合。两个模块的输出将在合并后输入后级的 BiLSTM。

功能上，DHGCN 通过超图分割实现超图到普通图的退化，该过程详见附录 B。对于包含  $T$  个时刻的历史数据，将可获得为  $T$  个超图，标记为  $G^1, \dots, G^t, \dots, G^T$ ，按时间步逐个输入 DHGCN。连续输入的超图结构将进行动态信息聚合，由于超图已包含风机地理位置，所以在这一过程，实时的动态空间关联被提取。

在 DHGCN 的基础上引入 CNN 是为了赋予 STAFEM 对时序特征的理解、处理能力。功能上，CNN 通过聚合运算提取风功率时序特征，特征提取过程为原始数据的局部低维特征被映射到高维特征。经过内部卷积层提取特征之后，进行池化操作。经过池化操作后的数据对应原始数据会拥有更大的感受野，通过降低图的空间维度，减少计算量，同时提取并强化特征。本文利用 CNN 对功率序列进行特征提取。CNN 提取到的时序特征将同 DHGCN 提取的时空特征合并为时空聚合特征（Spatio-Temporal Aggregation Feature, STAF）后一同输入 BiLSTM 进行特征学习。

## 2.4 BiLSTM

特征提取完毕后，所产生的特征信息内部隐含复杂因果关系，在信息流中不断传递及变化。

为了同时拟合顺向传播及逆向传播的时序特征，本文构建了基于 BiLSTM 的复合时空特征拟和结构。BiLSTM 是一种循环神经网络（Recurrent Neural Network, RNN）的变体，由一对异向 LSTM 头尾级联而成，其拥有 LSTM 在解决梯度爆炸问题上的优异性能，同时相较于 LSTM 来说，BiLSTM 还可关注逆向序列变化的内在联系，能够兼顾双向时序信息，更加适用于复杂的风电时空特征拟合。该技术在预测领域以广泛使用<sup>[36-37]</sup>，故不再赘述。

## 2.5 预测流程

基于上文所述技术要点，本文构建了基于尾流关联的动态超图风电功率预测模型。主要包含：构建基于尾流关联的动态超图、基于 DHGCN 的 STAFEM、BiLSTM 的时空特征拟合模块。具体结构见图 9。

1) 构建基于尾流关联的动态超图：基于尾流关联建立动态超图的信息结构。即，通过 J-model 中的尾流扩散模型为依据，选定超边、构建超图。具体为：首先，从 SCADA 系统以及气象站统计历史中分别读取风功率  $P = \{P^1, \dots, P^t, \dots, P^T\}$  以及区域风向数据  $WD = \{WD^1, \dots, WD^t, \dots, WD^T\}$ 。其中， $P^t$  为  $t$  时刻集群风机的功率序列； $WD^t$  为  $t$  时刻，集群风机所在区域的风向数据； $P$  与  $WD$  的数据分辨率为 15min。之后，利用 K-means 聚类以及三次样条插值分别对  $P$  及  $WD$  中的异常数据进行识别与重构。再之后，以单时刻为构建步长，风功率为顶点特征，根据动态尾流关联及风向构建超图。以  $t$  时刻的超图构建为例，步骤为：风机坐标读入与转换；读取  $WD^t$  并确定受风顺序；根据受风顺序放置尾流辐射区域；对处于同一尾流辐射区域的风机划归至同一超边；合并重复超边并以  $P^t$  构成动态超图  $G^t$ 。上述步骤在遍历全部数据后，可获得各时刻数据对应的超图，各超图按时间顺序传播过程的串联可构成动态超图。最后，动态超图将输入后级 DHGCN 中做进一步的特征提取。

2) 基于 DHGCN 的 STAFEM：为了实现功率时序特征与集群时空特征的同步利用，本文构建了基于 DHGCN 的 STAFEM：由 DHGCN、CNN 并行构成，分别处理动态超图信息、风功率序列信息。以  $t$  时刻的 STAFEM 处理过程为例：基于尾流关联的超图  $G^t$  将输入至 DHGCN



进行时空特征提取,即 DHGCN 在对单时间步内的图信息按照超边进行聚合,聚合将叠加提取超图中所包含的风机地理位置信息、气象信息以及关联风机的功率信息。 $P'$  将输入至一维 CNN,在池化机制作用下,CNN 感受野内的点阵信息将被整合,获得风功率的时序特征。当模块连续处理复合时空信息时,DHGCN 的输出将包含各顶点的动态时空特征,CNN 的输出将包含连续的风功率时序特征,这两种特征在合并为 STAF 输入至后级的 BiLSTM。

3) BiLSTM 的时空特征拟合模块:由上级

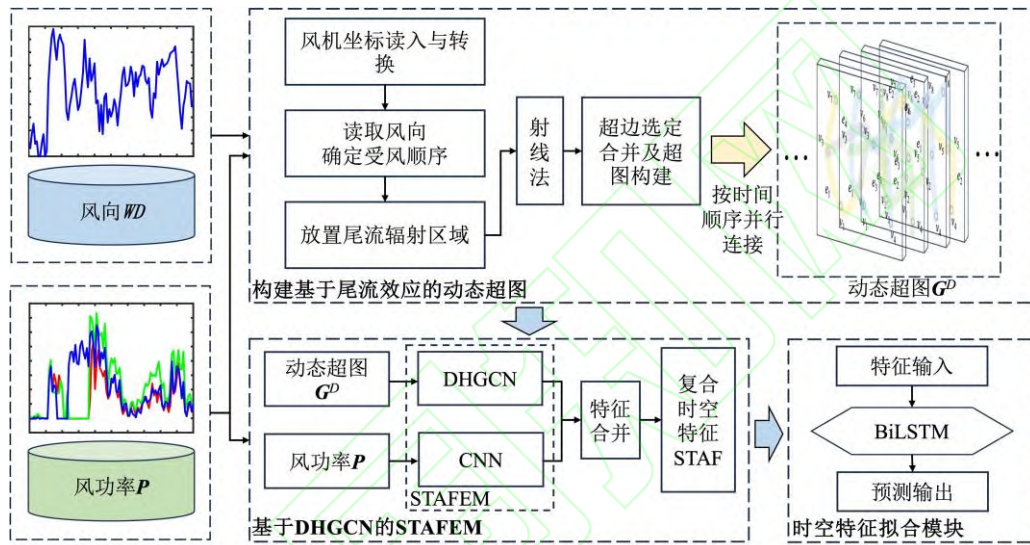


图 9 总体预测流程

Fig. 9 Overall prediction process

### 3 算例分析

#### 3.1 实验设置

本文仿真通过 Pytorch 框架的 Python 语言实现,主机系统为 Windows11,仿真主机硬件参数为:CPU 为 Intel Core i7-13700H 2.40 GHz,内存 RAM 为 16GB,GPU 为 Nvidia GeForce RTX 4060,并利用 CUDA 架构实现 GPU 加速运算。为了验证本文模型的准确性,利用某风电集群 30 台风机实测数据进行仿真,空间分布图见图 C1 (见附录 C)。

数据包含 2023 年 1 月 1 日至 2023 年 7 月 17 日的风功率、风向信息,时间分辨率为 15min,共 18810 条。将数据集划分为训练集、验证集和测试集。训练集用来训练预测模型的各种参数,验证集用来验证模型是否建立合适,测试集用来进行实际的预测。取其中 1~13167 条数据作为训练集,13168~16929 条数据作为验证集,16930~18810 条数据作为测试集。本文利用滑动

STAFEM 提取特征信息其内部隐含复杂因果关系,信息流中不断传递及变化。为了同时拟合顺向传播及逆向传播的时序特征,本文构建了基于 BiLSTM 的复合时空特征拟合结构。BiLSTM 由一对异向 LSTM 头尾级联而成,延续了 LSTM 在解决梯度问题的优异性能,还可关注逆向序列变化的内在联系。STAF 将输入 BiLSTM,进行模型训练,通过迭代不断修正内部参数,直至满足误差阈值,之后输出 BiLSTM 特征拟合模型,并进行预测。

窗口按时刻输入数据进行特征提取。仿真参数设置与预测指标见附录 C。

#### 3.2 超图构建策略对比

为了刻画集群内风机间的复杂多元关系,本文利用尾流关联构建了动态超图结构。为了验证基于尾流关联的动态超图构建方法的有效性,共进行两方面的仿真验证:(1)对比常见的斯皮尔曼关联(动态)以及斯皮尔曼关联(静态),验证尾流关联是否具有更高的可解释性;(2)在本文所提出预测框架上,以三种图构建方法构建超图结构并进行预测,基于尾流关联的预测模型是否具有更高精度。其中,基于尾流关联以及斯皮尔曼关联(动态)的超图为动态图结构,基于斯皮尔曼关联(静态)的超图为静态图结构。斯皮尔曼关联(动态)通过斯皮尔曼关联系数的选定超边,具体为利用滑动窗口输入包含 10 个相邻时刻的风机功率序列,计算各序列间的关联系数,按风机选择与之关联性较高的 10 台风机构

成超边；斯皮尔曼关联（静态）通过计算各风机功率序列的关联系数，按风机选择与之关联性较大的 10 台风机构成超边。为了简化描述将尾流关联定义为策略一、斯皮尔曼关联（动态）定义为策略二、斯皮尔曼关联（静态）定义为策略三。图 D1（见附录 D）为三种构建策略所生成的同一时刻的超图结果（风向为 231 度）。图中矩形填充的不同颜色表示不同超边。

如图 D1 所示，基于策略一的超边数量多于其他的构建策略。观察单条超边内包含的风机数量发现，该情况下的超边重合的现象远低于其他的构建方法。由此可知，基于策略一构建的超图所表达的多元关联最为纯粹，出现非关联信息冗余的可能性最小。且观测对应的风向信息，策略一所构建的超边具备极强的可解释性。基于三种超图构建策略的预测结果见表 1。

表 1 基于不同超图构建策略的预测对比

Tab. 1 Comparison of predictions based on different

hypergraph construction strategies

预测模型	$y_{mae}/\%$	$y_{rmse}/\%$	$R^2/\%$
本文模型（策略一）	2.28%	2.83%	99.11%
本文模型（策略二）	3.08%	3.69%	98.92%
本文模型（策略三）	3.39%	3.90%	98.69%

如表 1 所示，三个预测模型都具有较高预测精度，而基于策略一、二的模型预测性能有进一步的提升：MAE, RMSE 相较于策略三分别降低了 1.11%、0.31%、1.07%、0.21%； $R^2$  提高了 0.19%、0.23%，这是由于在较小时间尺度上，风机的时空特征与总体宏观层面有区别，而动态超图关注特征动态变化，可以更全面地表征风机间的复杂动态关系，结合 DHGCN 对高动态信息的处理，关键时空特征被凸显，降低了 BiLSTM 的拟合复杂度。对比基于策略一以及策略二的预测结果可知，策略一的 MAE, RMSE 分别降低了 0.80%、0.86%， $R^2$  提高了 0.19%。策略一以及策略二的区别在于是否有效结合物理过程，策略一借助尾流传播构建超边，策略二的超边构建完全依赖数据分析，因此基于前者的预测模型的内部数据传递将更接近实际运行过程，反映到预测结果上，即：基于策略一的预测模型的输出结果处于更低的误差水平。为了展示预测细节，选择 96 个样本绘制折线对比图，具体见图 10。所选择 96 个样本所在风功率序列段包含明显的波动性以及突变型，可充分验证模型的性

能。




图 10 基于不同超图构建策略的预测对比

Fig. 10 Comparison of predictions based on different

hypergraph construction strategies

如图 10 所示。基于策略一的模型输出结果对实际功率序列的跟随效果更好，更接近实际数值。由此可知，在融入动态物理信息后，模型对风功率变化趋势的描述更加全面，预测精度显著提升。

### 3.3 图预测模型对比

为了验证本文模型应用于风功率预测的有效性，对比目前主流图结构预测方式：HGCN、时空图卷积神经网络（Spatio-Temporal Graph Convolutional Networks, STGCN）、GAT、GCN。为了保持对比过程中的变量稳定，本文构建了 DHGCN-BiLSTM（三种策略）、CNN-HGCN-BiLSTM、HGCN-BiLSTM、CNN-STGCN-BiLSTM、CNN-GAT-BiLSTM、CNN-GCN-BiLSTM、STGCN-BiLSTM、GAT-BiLSTM 以及 GCN-BiLSTM，与本文模型进行对比实验。

其中，DHGCN-BiLSTM（三种策略）、HGCN-BiLSTM、STGCN-BiLSTM、GAT-BiLSTM 以及 GCN-BiLSTM 不包含用于提取时序特征的 CNN；CNN-STGCN-BiLSTM、CNN-GAT-BiLSTM、CNN-GCN-BiLSTM 与本文模型一致，均采用时空特征、时序特征的并行处理结构，区别在于将 DHGCN 替换为其他图结构。不同预测模式的结果汇总至表 2。

由表 2 可知，包含有利用超图信息结构的预测模型预测精度均高于其他常规图模型，其中，本文模型的预测精度最高。这是因为包含于超图内的风机将处于多元信息耦合状态，虽然超图卷积（包括 DHGCN）的信息传播机制最终将超图结构简化为普通图，但在传播中，原本超图包含

的信息不断聚合，使最终输出特征将包含原始的多元关联信息。

表 2 图预测模型对比

Tab. 2 Comparison of graph prediction models

预测模型	$y_{mae}$	$y_{rmse}$	$R^2$
本文模型	2.28%	2.83%	99.11%
DHGCN-BiLSTM（策略一）	3.15%	3.66%	98.88%
DHGCN-BiLSTM（策略二）	3.43%	4.06%	98.61%
DHGCN-BiLSTM（策略三）	3.71%	4.33%	98.41%
CNN-HGCN-BiLSTM	3.88%	4.51%	98.29%
HGCN-BiLSTM	4.05%	4.79%	97.96%
CNN-STGCN-BiLSTM	4.06%	4.73%	98.10%
CNN-GAT-BiLSTM	4.32%	5.04%	97.84%
CNN-GCN-BiLSTM	4.56%	5.35%	97.51%
STGCN-BiLSTM	4.97%	5.80%	97.06%
GAT-BiLSTM	5.28%	6.14%	96.66%
GCN-BiLSTM	5.90%	6.87%	95.77%

包含 DHGCN 在的超图卷积有效提取了复杂、全面的时空信息，有利于提高预测性能。对比其他包含超图的预测模型与本文模型间的结果差异可知，本文模型的 MAE，RMSE 分别降低了 0.87%，1.15%，1.43%，1.60%，1.77%，0.83%，1.23%，1.50%，1.68%，1.96%， $R^2$  提高了 0.23%，0.50%，0.70%，0.82%，1.15%。从信息复合度角度，本文模型将包含更深层的时空特征，可进行更细致的模型运算。对比本文模型与 DHGCN-BiLSTM（策略一）、CNN-HGCN-BiLSTM 与 HGCN-BiLSTM 的预测效果可知，CNN 的加入有助于提升超图模型的预测性能。该结论也可在常规图预测模型的对比中得到验证：包含 CNN 的常规图预测模型输出精度明显更高。图 D2（见附录 D）展示了本文与对比模型的 96 个样本可视化预测结果。如图 D2 所示，总体上，各模型对实际功率的跟随效果从高到低的排序为：本文模型>动态超图模型（不包含 CNN）>超图模型（包含 CNN）>超图模型（不包含 CNN）>常规图模型（包含 CNN）>常规图模型（不包含 CNN）。这与模型所利用信息的复合度排序一致，本文模型同时利用 DHGCN、CNN 分别作用于时空特征以及时序信息，信息聚合度最高，预测精度也最高。

3.4 模型可用性对比

为了深度探究模型预测精度，章节 3.2 与章节 3.3 所涉及实验均采用单风机（#1）、单步输出形式。虽然可以验证模型有效性，但无法证明

模型具备实际的应用价值。对此，本文与目前主流的“特征提取+时序拟合”式预测模型以不同输出模式、不同风机以及集群总功率预测进行多角度对比实验，以验证本文模型的实际应用价值。本部分仿真充分考虑目前的主流预测技术：CNN、CBAM、BiLSTM、XGBoost、GRU，将其组合为如下对比预测模型，CNN-CBAM-BiLSTM（CCBL）、CNN-CBAM-XGBoost（CCXG）以及 CNN-CBAM-GRU（CCG），输入对比预测模型的数据与本文模型一致，均为 30 台风机的风功率序列。其中，CBAM<sup>[38]</sup>为公认的性能最强大的非图特征提取模型，所以选择以 CBAM 构建的预测模型与本文模型进行仿真对比。不同输出模式预测评价包含 3 种预测模式，具体为：提前 0.5 小时（单次输出为 2）；提前 1 小时（单次输出为 4）；提前 2 小时（单次输出为 8）。不同风机预测评价从集群中选择 4 台风机，以提前 2 小时为预测模式，分析不同模型对其预测结果的差异。集群总功率预测评价为预测 30 台风机的风功率总和。各模型具体参数见表 D1（见附录 D），其中 BiLSTM 的模型参数与本文模型一致。

3.4.1 不同输出模式预测评价

表 3 展示不同输出模式下的预测结果精度。

表 3 不同输出模式预测对比

Tab. 3 Comparison of predictions for different output modes

预测模式	预测模型	$y_{mae}/\%$	$y_{rmse}/\%$	$R^2/\%$
0.5h-ahead	本文模型	4.50%	5.25%	97.62%
	CCBL	5.03%	5.88%	96.97%
	CCXG	5.37%	6.29%	96.54%
	CCG	5.62%	6.57%	96.18%
1h-ahead	本文模型	5.19%	6.08%	96.74%
	CCBL	5.77%	6.78%	95.87%
	CCXG	6.34%	7.46%	95.02%
	CCG	6.73%	7.99%	94.21%
2h-ahead	本文模型	5.60%	6.58%	96.16%
	CCBL	6.03%	7.05%	95.53%
	CCXG	6.54%	7.67%	94.75%
	CCG	6.91%	8.12%	93.88%

如表 3 所示，随着预测输出的增加，各模型精度都有不同程度的下降，但本文模型的精度损失最小：从 0.5h-ahead 增加至 2h-ahead， $R^2$  仅降低了 1.46%，MAE 和 RMSE 分别小幅度增加 1.10%、1.33%。其他对比模型在融入 CBAM 后，其特征识别及提取能力有明显提升，在多输



出预测时的性能衰减也能维持在相对较低水平。  
CNN-CBAM 结构更擅长时序信息处理，而时序特征在长时间跨度中传播中会逐步模糊，导致 CNN-CBAM 的提取结果也与实际特征逐步相异。相比之下，除利用 CNN 把握时序特征外，本文模型还通过 DHGCN 对包含尾流关联的动态时空信息进行特征提取。由于时空特征的高动态性，其不会随时间变化而失真。因此，本文模型可在不同预测模式下均具有较高精度。选择 96 个进行局部可视化分析，见图 D3（见附录 D）。如图 D3 所示，本文模型的输出结果误差最小，跟随效果最好，尤其是针对连续时序内的突变明显的序列段的变化趋势还原度最高；相同输出模式下，其余模型的预测结果会产生较大的偏移，预测精度低于本文模型。

3.4.2 不同风机预测评价

为了验证本文模型对不同风机的普适性，选择#2、#13、#21 以及#23 四台风机进行预测对比。这四台风机分散于风电集群中。#23 以及#2 风机处于集群边缘，分别位于地理方位北与方位南，该两台风机在不同风向下，更易成为最上游风机。#13 以及#21 风机处于集群内部，周围有多台风机。因此，#13 以及#21 风机将更易受到上游风机的尾流影响，所处功率变化将更复杂。各风机的预测结果汇总至表 4。

表 4 不同风机预测对比

Tab. 4 Comparison of different wind turbine predictions

风机编号	预测模型	$y_{mae}/\%$	$y_{rmse}/\%$	$R^2/\%$
#2 (2h-ahead)	本文模型	3.53%	4.36%	96.68%
	CCBL	3.94%	4.92%	95.68%
	CCXG	4.05%	5.02%	95.48%
	CCG	4.50%	5.72%	94.12%
	CCBL*	4.13%	4.99%	94.66%
#13 (2h-ahead)	本文模型	3.52%	4.56%	96.88%
	CCBL	3.96%	5.22%	96.03%
	CCXG	4.06%	5.20%	95.78%
	CCG	4.27%	5.47%	95.43%
	CCBL*	4.69%	6.26%	92.82%
#21 (2h-ahead)	本文模型	4.67%	5.61%	97.07%
	CCBL	5.11%	6.17%	96.54%
	CCXG	5.44%	6.57%	95.97%
	CCG	5.70%	6.87%	95.53%
	CCBL*	4.26%	4.88%	95.53%
#23 (2h-ahead)	本文模型	4.48%	5.56%	96.36%
	CCBL	4.70%	5.83%	96.11%
	CCXG	5.24%	6.53%	95.12%
	CCG	5.60%	6.97%	94.28%
	CCBL*	5.22%	6.74%	90.24%

由表 4 知，本文模型针对不同风机风功率的预测误差均最小，且不同风机间的预测表现相

近，可认为处于同一水平。可知，通过将超图中的复杂信息带入预测模型，将模型学习到更全面信息，使得其在复杂空间场景下的预测不会出现性能下滑。并选择 96 个进行局部可视化分析，见图 D4（见附录 D）。

3.4.3 集群总功率预测评价

本文通过对不同风机的预测输出求和，以获得集群总功率。为了验证本文建模方法在集群总功率预测上的有效性与适用性，对比本文模型与传统模型单场站整体建模方法（选择对比模型中预测误差最小的模型进行单序列预测，本文选择 CCBL 进行实验，记作 CCBL\*，采取“总功率推总功率”的预测方式）、传统模型单机预测求和建模方法（CCBL、CCXG、CCG 均采用“预测+求和”的预测方式）。表 5 汇总了不同模型对集群总风功率的预测情况。

表 5 集群总功率预测对比

Tab. 5 Cluster total power prediction comparison

预测模式	预测模型	$y_{mae}/\%$	$y_{rmse}/\%$	$R^2/\%$
0.5h-ahead	本文模型	3.49%	3.99%	96.98%
	CCBL	3.64%	4.16%	96.79%
	CCXG	3.95%	4.52%	96.20%
	CCG	4.08%	4.67%	95.87%
	CCBL*	4.13%	4.99%	94.66%
1h-ahead	本文模型	3.79%	4.34%	96.48%
	CCBL	3.94%	4.51%	96.07%
	CCXG	4.06%	4.65%	95.84%
	CCG	4.25%	4.87%	95.41%
	CCBL*	4.69%	6.26%	92.82%
2h-ahead	本文模型	4.26%	4.88%	95.53%
	CCBL	4.42%	5.08%	94.99%
	CCXG	4.61%	5.30%	94.64%
	CCG	4.80%	5.50%	94.16%
	CCBL*	5.22%	6.74%	90.24%

由表 5 与图 D5 知，在不同预测模式下，本文模型对总功率的预测误差均最小。横向比较单机与集群预测结果，可知：各模型的总功率预测结果误差更大，这是由于通过单机预测值的误差在求和计算总功率时不断累加，最终以误差“膨胀”的表现形式反映在集群总功率上。虽然如此，但本文模型的总体表现仍处于最佳状态，而采用传统整站建模方式的 CCBL\*的精度远低于其他“预测+求和”的预测方式的模型。在 2h-ahead 场景下，本文模型的 MAE，RMSE 分别降低了 0.16%，0.35%，0.54%，0.96%，0.20%，

0.42%, 0.62%, 1.86%,  $R^2$  提高了 0.54%、0.89%、1.37%、5.29%。

## 4 结论

精确的风电功率预测,可以减轻调度压力、降低风电场考核成本,对电网的规划端和决策端和电力系统安全稳定运行具有十分重要的现实意义。因此,本文提出一种基于尾流关联的动态超图风电功率预测方法,得出如下结论:

1) 本文在风功率预测领域首次提出动态超图表示结构,突破了图表示结构仅能描述风机间的二元关系与静态图结构无法细致描述风电机组间动态时空关联特性的限制,更好的表述了风电机组之间复杂的多元关系,从而提升风功率预测精度。

2) 基于尾流关联的动态超图构建方式将物理模型与深度学习模型深度耦合,在提升预测精度的同时赋予深度学习模型较强的可解释性。

3) 针对动态超图表示结构而设计的基于 DHGCN 的 STAFEM,并利用 BiLSTM 实现风电功率精确预测,从而为新能源并网提供数据源侧的支撑。

4) 在多应用场景下,相较于传统预测以及图预测模型均展现了更好的预测效果,具备优越的鲁棒性和强大的预测性能。

需要注意的是,本文数据结构与网络结构相较于图结构和简单网络来说较为复杂,训练用时较长,同时对数据质量的要求较高,在未来的工作中,会将研究重点放在异常数据的识别与清洗和动态超图卷积的轻量化处理两个方面,并将该方法拓展到多场预测之中。

## 参考文献

- [1] 国家能源局发布 2022 年全国电力工业统计数据[J]. 电力勘测设计,2023(1):24.
- [2] 舒印彪;赵勇;赵良;邱波;刘美;杨阳. “双碳”目标下我国能源电力低碳转型路径[J]. 中国电机工程学报, 2023,43(5):1663-1672.DOI:10.13334/j.0258-8013.pcsee.221407
- [3] 王廷涛;苗世洪;姚福星;刘志伟;张松岩.计及动态频率响应约束的高比例风电电力系统日前-日内联合调度策略[J/OL]. 中国电机工程学报,1-19[2023-11-24]<http://kns.cnki.net/kcms/detail/11.2107.TM.20230307.1802.002.html>.
- [4] 冯双磊,王伟胜,刘纯等.风电场功率预测物理方法研究[J]. 中国电机工程学报,2010,30(2):1-6.DOI:10.13334/j.0258-8013.pcsee.2010.02.014.
- [5] Li L, Liu Y, Yang Y, et al. A physical approach of the short-term wind power prediction based on CFD pre-calculated flow fields[J]. Journal of Hydrodynamics, Ser. B, 2013, 25(1): 56-61.
- [6] Allen D J, Tomlin A S, Bale C S E, et al. A boundary layer scaling technique for estimating near-surface wind energy using numerical weather prediction and wind map data[J]. Applied energy, 2017, 208: 1246-1257.
- [7] Singh S N, Mohapatra A. Repeated wavelet transform based ARIMA model for very short-term wind speed forecasting[J]. Renewable energy, 2019, 136: 758-768.
- [8] 王彩霞,鲁宗相,乔颖等.基于非参数回归模型的短期风电功率预测[J]. 电力系统自动化,2010,34(16):78-82+91.
- [9] 周玮;钟佳成;孙辉;李国锋;孔剑虹;张富宏.基于隐马尔可夫模型的日内风电功率预测误差区间滚动估计[J]. 电力系统自动化,2018,42(21):90-95+184.
- [10] Shahid F, Zameer A, Muneeb M. A novel genetic LSTM model for wind power forecast[J]. Energy, 2021, 223: 120069.
- [11] Li C, Tang G, Xue X, et al. Short-term wind speed interval prediction based on ensemble GRU model[J]. IEEE transactions on sustainable energy, 2019, 11(3): 1370-1380.
- [12] Wu Y K, Huang C L, Wu S H, et al. Deterministic and probabilistic wind power forecasts by considering various atmospheric models and feature engineering approaches[J]. IEEE Transactions on Industry Applications, 2022, 59(1): 192-206.
- [13] Chen J, Zhu Q, Li H, et al. Learning heterogeneous features jointly: A deep end-to-end framework for multi-step short-term wind power prediction[J]. IEEE Transactions on Sustainable Energy, 2019, 11(3): 1761-1772.
- [14] Wang J, Zhu H, Cheng F, et al. A novel wind power prediction model improved with feature enhancement and autoregressive error compensation[J]. Journal of Cleaner Production, 2023, 420: 138386.
- [15] 盛四清,金航,刘长荣.基于 VMD-WSGRU 的风电场发电功率中短期及短期预测[J]. 电网技术, 2022,46(3):897-904.DOI:10.13335/j.1000-3673.pst.2020.1198.
- [16] 陈海鹏,李赫,阚天洋等.考虑风电时序特性的深度小波-时序卷积网络超短期风功率预测[J]. 电网技术, 2023,47(4):1653-1665.DOI:10.13335/j.1000-3673.pst.2022.1019.
- [17] Ye L, Dai B, Li Z, et al. An ensemble method for short-term wind power prediction considering error

- correction strategy[J]. *Applied Energy*, 2022, 322: 119475.
- [18] 刘雨佳,樊艳芳,白雪岩等.基于特征交叉机制和误差补偿的风力发电功率短期预测[J].*电工技术学报*,2023,38(12):3277-3288.DOI:10.19595/j.cnki.1000-6753.tces.220477.
- [19] 符杨,任子旭,魏书荣等.基于改进 LSTM-TCN 模型的海上风电超短期功率预测[J].*中国电机工程学报*,2022,42(12):4292-4303.DOI:10.13334/j.0258-8013.pcsee.210724.
- [20] 吕云龙,胡琴,熊俊杰等.基于时空注意力卷积模型的超短期风电功率预测[J/OL].*电网技术*:1-13[2023-11-09].<https://doi.org/10.13335/j.1000-3673.pst.2023.0899>.
- [21] Li Z, Ye L, Zhao Y, et al. A Spatiotemporal Directed Graph Convolution Network for Ultra-Short-Term Wind Power Prediction[J]. *IEEE Transactions on Sustainable Energy*, 2022, 14(1): 39-54.
- [22] Chengqing Y, Guangxi Y, Chengming Y, et al. A multi-factor driven spatiotemporal wind power prediction model based on ensemble deep graph attention reinforcement learning networks[J]. *Energy*, 2023, 263: 126034.
- [23] Pourhabib A, Huang J Z, Ding Y. Short-term wind speed forecast using measurements from multiple turbines in a wind farm[J]. *Technometrics*, 2016, 58(1): 138-147.
- [24] Wang F, Chen P, Zhen Z, et al. Dynamic spatio-temporal correlation and hierarchical directed graph structure based ultra-short-term wind farm cluster power forecasting method[J]. *Applied Energy*, 2022, 323: 119579.
- [25] 王玉庆,徐飞,刘志坚等.基于动态关联表征与图网络建模的分布式光伏超短期功率预测[J].*电力系统自动化*,2023,47(20):72-82.
- [26] Song Y, Tang D, Yu J, et al. Short-Term Forecasting Based on Graph Convolution Networks and Multiresolution Convolution Neural Networks for Wind Power[J]. *IEEE Transactions on Industrial Informatics*, 2022, 19(2): 1691-1702.
- [27] 孙亦皓,刘浩,胡天宇等.基于时空关联特征与 GCN-FEDformer 的风速短期预测方法[J/OL].*中国电机工程学报*:1-10[2023-11-24].<https://doi.org/10.13334/j.0258-8013.pcsee.231140>.
- [28] Feng Y, You H, Zhang Z, et al. Hypergraph neural networks[C]. *Proceedings of the AAAI conference on artificial intelligence*. 2019, 33(1): 3558-3565.
- [29] 林晶晶,冶忠林,赵海兴等.超图神经网络综述[J/OL].*计算机研究与发展*:1-25[2024-02-03].<http://kns.cnki.net/kcms/detail/11.1777.TP.20230525.1654.004.html>.
- [30] 王金水,欧雪雯,陈俊岩等.基于时空超图卷积模型的城市轨道站点客流预测[J].*铁道科学与工程学报*,2023,20(12):4506-4516.
- [31] Xue J, Hu J, Wang Y, et al. Hypergraph membrane system based F2 fully convolutional neural network for brain tumor segmentation[J]. *Applied Soft Computing*, 2020, 94: 106454.
- [32] Nong L, Wang J, Lin J, et al. Hypergraph wavelet neural networks for 3D object classification[J]. *Neurocomputing*, 2021, 463: 580-595.
- [33] Hao X, Li J, Guo Y, et al. Hypergraph neural network for skeleton-based action recognition[J]. *IEEE Transactions on Image Processing*, 2021, 30: 2263-2275.
- [34] 葛维春,李景瑞,滕云等.基于尾流风速场风速矢量计算的风电场输出功率优化模型[J].*太阳能学报*,2019,40(3):641-648.DOI:10.19912/j.0254-0096.2019.03.007.
- [35] Jensen N O. A note on wind generator interaction[M]. Roskilde, Denmark: Risø National Laboratory, 1983.
- [36] Zou M, Holjevac N, Đaković J, et al. Bayesian cnn-bilstm and vine-gmcm based probabilistic forecasting of hour-ahead wind farm power outputs[J]. *IEEE Transactions on Sustainable Energy*, 2022, 13(2): 1169-1187.
- [37] 张淑清,李君,姜安琦等.基于 FPA-VMD 和 BiLSTM 神经网络的新型两阶段短期电力负荷预测[J].*电网技术*,2022,46(8):3269-3279.DOI:10.13335/j.1000-3673.pst.2021.0969.
- [38] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]. *Proceedings of the European conference on computer vision (ECCV)*. 2018: 3-19.



## 附录 A 基于尾流关联的动态超图构建过程

1) 风机坐标读入与转换：通常以经纬坐标表示集群内风机地理位置。为了方便后续计算，在读入风机地理信息后，以经度、维度最小值 ( $LATD_{\min}, LOTD_{\min}$ ) 为原点，将经纬坐标转化为平面距离坐标。其中， $LATD_{\min}$  表示全部风机中的最小经度值， $LOTD_{\min}$  表示全部风机中的最小纬度值，第  $i$  台风机坐标  $(\Delta d_{v,i}, \Delta d_{h,i})$  满足以下计算：

$$\Delta d_{v,i} = 110000 \times (\Delta LATD_i - LATD_{\min}) \times \cos(\Delta LOTD_i - LOTD_{\min}) \quad (1)$$

$$\Delta d_{h,i} = 110000 \times (\Delta LATD_i - LATD_{\min}) \quad (2)$$

2) 读取风向确定受风顺序：在已有坐标信息之上，根据当前时刻风向，确定各风机的受风顺序：假设任意时刻的风均平行扫过风电集群，则受风顺序为平行风扫过各风机的先后顺序，先受风的风机即为上游风机。在该过程中，第  $j$  时刻的风向  $\theta_j$  为风径向与正东方向的夹角， $\theta_j \in [0, 360]$ 。

3) 放置尾流辐射区域：按照受风顺序，从最上游风机开始逐个放置梯形尾流辐射区域，假设所有区域均风向辐射至无穷远处。之后，采用所提出的“射线法”从最上游风机开始逐个计算下游风机是否位于其尾流所覆盖范围。其中，射线法的设计思路来源于 J-model。J-model 规定了尾流辐射为固定模式：作用范围沿风向法线向外线性扩散。图 A1 表示了利用射线法判断上游风机的尾流覆盖情况。其中，圈注的风机是受到尾流影响的风机。




图 A1 射线法判断上游风机尾流覆盖情况

Fig. A1 Radial method to judge the wake coverage of upstream turbines

如图 A1 所示，首先定义产生尾流的上游风机为头部风机，其余为受扰风机。通过风机位置坐标、风机叶轮半径  $r_0$  以及风向  $\theta_j$ ，计算风机叶轮边缘的坐标。以计算头部风机的  $(x_{0,1}, y_{0,1})$  为例：

$$\begin{cases} x_{0,1} = x_0 - r_0 \times \sin(\theta) \\ y_{0,1} = y_0 + r_0 \times \cos(\theta) \end{cases} \quad (3)$$

之后，根据头部风机的叶轮边缘坐标以及 J-model 计算  $f_1$  及  $f_2$  表达式：

$$f_1(x) = \tan(\theta + \arctan(k))(x - x_{0,1}) + y_{0,1} \quad (4)$$

$$f_2(x) = \tan(\theta - \arctan(k))(x - x_{0,2}) + y_{0,2} \quad (5)$$

其中， $f_1$  可视为尾流辐射区域上界， $f_2$  可视为尾流辐射区域下界。由此，对于受扰风机是否处于头部风机尾流范围的判断可转化为受扰风机的叶轮边缘坐标是否位于  $f_1$  之上或  $f_2$  之下。即，对第  $z$  台受扰风机处于尾流范围内可表示为：

$$Or \left( \begin{aligned} &f_1(x_{z,1}) < y_{z,1} \text{ and } f_1(x_{z,2}) < y_{z,1} \\ &f_2(x_{z,1}) > y_{z,1} \text{ and } f_2(x_{z,2}) > y_{z,1} \end{aligned} \right) \quad (6)$$

其中， $Or(\cdot)$  表示事件的逻辑或计算。通过上式，可将复杂几何问题简化为数值解析问题。

4) 超边选定、合并及超图构建：按照受风顺序确认尾流覆盖情况，将处于同一尾流覆盖区域的风机置于同一条超边之上，之后将获得  $n$  条超边，其中  $n$  为风机总数。将上游风机所产生超边定义为前级超边；将下游风机所产生超边定义为后级超边。由于采用顺序遍历选定超边可能导致超边重复：后级超边包含于前级超表中。所以超边选定后，以受风顺序的逆序查看超边结构。若某后级超边与某前级超边所包含顶点风机一致时，将该后级超边合并入该前级超边中。

5) 构建动态超图：以  $t$  时刻为例，超图  $G^t$  表示了  $t$  时刻风机内部的多元尾流关系。利用  $H^t$  储存顶点与超边的耦合关系，简化超图的表达。利用 1) 至 4) 遍历全部时刻数据后，即可获得全部的超图。将所有超图按照时间顺序并行连接构成动态超图  $G^D$ ，其结构信息储存在  $H$  内。

## 附录 B DHGCN 的运算过程

在超图退化到图的过程中，超图拉普拉斯用于解决超图分割优化问题。针对超图分割  $f$  的优

化可以表述为：

$$\begin{aligned} \operatorname{argmin}_{f \in V} \frac{1}{2} \sum_{e \in \mathcal{E}\{u,v\} \subseteq e} \frac{w(e)}{\delta(e)} \left( \frac{f(u)}{\sqrt{d(u)}} - \frac{f(v)}{\sqrt{d(v)}} \right)^2 \\ \text{s.t. } \sum_{v \in V} f^2(v) = 1, \sum_{v \in V} f(v) \sqrt{d(v)} = 0 \end{aligned} \quad (7)$$

其中， $u$  和  $v$  是超图中的顶点子集， $w(e)$  是超边  $e$  的权重，而  $\delta(e)$  和  $d(v)$  分别表示超边和顶点的度数。利用关联矩阵  $\mathbf{H}$ 、特征矩阵  $\mathbf{W}$ 、顶点度矩阵  $\mathbf{D}_v$  和超边度矩阵  $\mathbf{D}_e$ ，上式 (7) 可为：

$$f^\top f - f^\top \mathbf{D}_v^{-1/2} \mathbf{H} \mathbf{W} \mathbf{D}_e^{-1} \mathbf{H}^\top \mathbf{D}_v^{-1/2} f \quad (8)$$

令： $\mathbf{A} = \mathbf{I} - \mathbf{D}_v^{-1/2} \mathbf{H} \mathbf{W} \mathbf{D}_e^{-1} \mathbf{H}^\top \mathbf{D}_v^{-1/2}$ ，则可表示为：

$$2f^\top \mathbf{A} f \quad (9)$$

其中， $\mathbf{A}$  是一个正实值半正定矩阵，定义为拉普拉斯算子，是 DHGCN 中的关键部分。对于章节 2.1 中的具备  $n$  个顶点的超图结构，其对应的  $\mathbf{A}$  维度为  $n \times n$ ，由于内部包含元素 0，使其带有一定的稀疏性。通过矩阵分解  $\mathbf{A} = \Phi \mathbf{\Lambda} \Phi^\top$ ，可得到非负对角特征矩阵  $\mathbf{\Lambda}$ ，正定特征向量  $\Phi$ 。将  $\Phi$  作为谱序列  $\mathbf{x} = (x_1, \dots, x_n)$  的傅里叶基，则傅里叶变换定义为  $\hat{\mathbf{x}} = \Phi^\top \mathbf{x}$ 。因此，针对超图的卷积可以表示为：

$$\begin{aligned} (\mathbf{x} * \mathbf{g})_{HG} &= \Phi \left( (\Phi^\top \mathbf{g}) \odot (\Phi^\top \mathbf{x}) \right) \\ &= \Phi \mathbf{g}_\theta(\mathbf{\Lambda}) \Phi^\top \mathbf{x} \end{aligned} \quad (10)$$

其中， $\odot$  为两矩阵的元素的哈达玛乘积。 $\Phi^\top \mathbf{g}$  可视为特征值的滤波器，以  $\mathbf{g}_\theta(\mathbf{\Lambda})$  表示。之后，利用切比雪夫多项式来近似滤波器和超图信号的乘积以简化计算：

$$\begin{aligned} (\mathbf{x} * \mathbf{g})_{HG} &\approx \sum_{k=0}^{K-1} \Phi \theta_k T_k(\tilde{\mathbf{\Lambda}}) \Phi^\top \mathbf{x} \\ &\approx \sum_{k=0}^{K-1} \theta_k T_k(\tilde{\mathbf{\Lambda}}) \mathbf{x} \end{aligned} \quad (11)$$

其中， $\tilde{\mathbf{\Lambda}} = 2\mathbf{\Lambda} / \mathbf{\Lambda}_{\max} - \mathbf{I}_N$ ，为按  $[-1, 1]$  范围缩放后的特征矩阵。进行数值缩放是为了满足切比雪夫多项式截断展开的条件。同时设置谱半径  $\lambda_{\max}$  为 2，切比雪夫多项式系数  $\theta_k$  为 1。为了防止过拟合，定义：

$$\theta = -2\theta_1 = 2\theta_0 \mathbf{D}_v^{1/2} \mathbf{H}_d^{-1} \mathbf{W}^{-1} \mathbf{D}_e^{-1} (\mathbf{H}_d^\top)^{-1} \mathbf{D}_v^{1/2} \quad (12)$$

则卷积过程可表示为：

$$(\mathbf{x} * \mathbf{g})_{HG} \approx \theta \mathbf{D}_v^{-1/2} \mathbf{H}_d \mathbf{W} \mathbf{D}_e^{-1} \mathbf{H}_d^\top \mathbf{D}_v^{-1/2} \mathbf{x} \quad (13)$$

对应上述过程的卷积层并定义为：

$$\mathbf{X}^{(l+1)} = \sigma \left( \begin{pmatrix} (\mathbf{D}_v)^{-1/2} \mathbf{H}_d \mathbf{W} (\mathbf{D}_e)^{-1} \\ (\mathbf{H}_d)^\top (\mathbf{D}_v)^{-1/2} \end{pmatrix} \mathbf{X}^{(l)} \boldsymbol{\theta}^{(l)} \right) \quad (14)$$

利用式 (14) 所描述过程，可将不同时刻的风功率数据整合为超图形式。

## 附录 C 仿真设置

表 C1 模型参数

Tab. C1 Parameters of model

序号	参数	设定值	序号	参数	设定值
1	1D-CNN 层数	3	6	优化器	Adam
2	DHGCN 层数	2	7	激活函数	Relu
3	BiLSTM 层数	2	8	学习率	0.005
4	全连接层数	2	9	最大迭代次数	150
5	BiLSTM 神经元数	128/256	10	早停迭代次数	5




图 C1 风机分布情况

Fig. C1 The distributions of wind turbines

算例参考功率预测和新能源预测国标，采用方均根误差 (Root Mean Square Error, RMSE)、平均误差 (Mean Absolute Error, MAE) 和拟合度 (R-squared,  $R^2$ ) 作为仿真的综合评估损失函数。各指标的计算过程为：


$$y_{\text{rmse}} = \frac{1}{\text{Cap}} \sqrt{\frac{\sum_{i=1}^n (x_{\text{act},i} - x_{\text{pred},i})^2}{n}} \times 100\% \quad (15)$$

$$y_{\text{mae}} = \frac{1}{\text{Cap}} \frac{\sum_{i=1}^n |x_{\text{act},i} - x_{\text{pred},i}|}{n} \times 100\% \quad (16)$$

$$R^2 = \left( 1 - \frac{\sum_{i=1}^n (x_{\text{act},i} - x_{\text{pred},i})^2}{\sum_{i=1}^n (x_{\text{act},i} - \bar{x}_{\text{pred}})^2} \right) \times 100\% \quad (17)$$


其中,  $n$  为预测样本数,  $x_{\text{act},i}$  和  $x_{\text{pred},i}$  分别为  $i$  时刻的实际值和预测值,  $\overline{x_{\text{pred}}}$  为预测样本均值, Cap 为集群装机容量。

## 附录 D 仿真结果



(a) 策略一

(a) Strategy I



(b) 策略二

(b) Strategy II

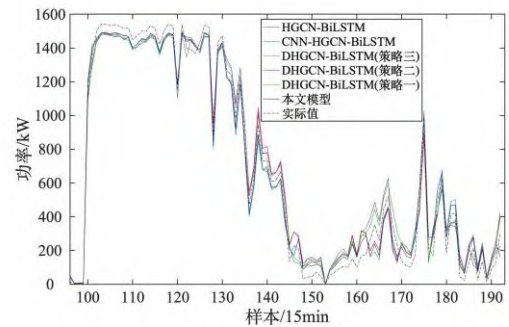


(c) 策略三

(c) Strategy III

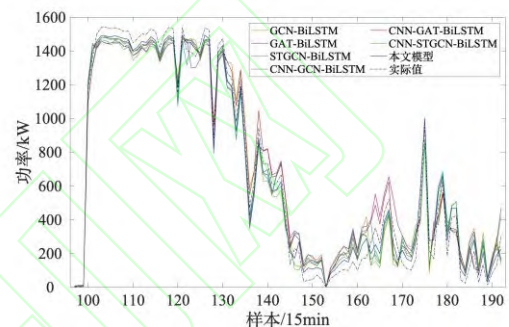
图 D1 不同超图构建策略对比

Fig. D1 Comparison of different hypergraph construction strategies



(a) 本文模型与其他超图模型对比

(a) Comparison between the proposed model and the conventional hypergraph model

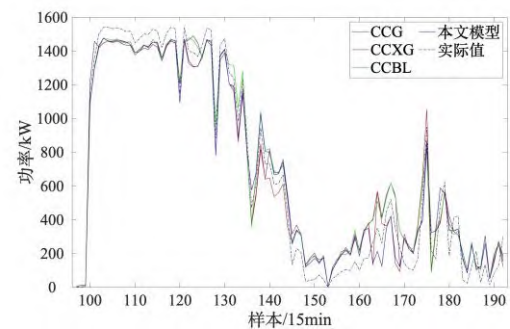


(b) 本文模型与常规图模型的对比

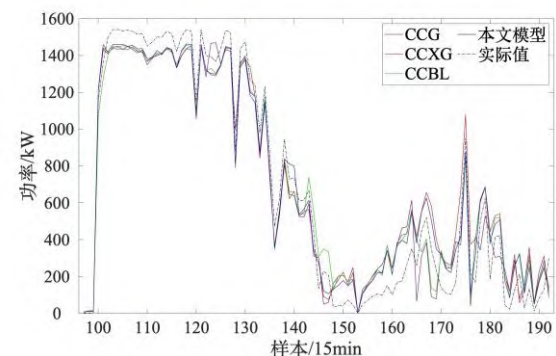
(b) Comparison between the proposed model and the normal graph model

图 D2 本文模型与其他图预测模型对比

Fig. D2 Comparison between proposed model and other prediction models based on graph




(a) 0.5h-ahead



(b) 1h-ahead





(c) 2h-ahead


图 D3 不同输出模式预测对比

Fig.D3 Comparison of predictions for different output modes

表 D1 对比模型参数


Tab. D1 Parameters of comparison models

模型	参数	设定值
CBAM	通道注意力模块输入数	32
	通道下降倍数	4
	激活函数	Relu
	空间注意力卷积核	[7,7]
XGBoost	学习率	0.05
	L1 正则化权重项	0.1
	L2 正则化权重项	0.1
	最大树深度	6
	最小子节点权重和	1
GRU	分支衰减最小值	0.3
	GRU 层数	2
	隐含层数	3



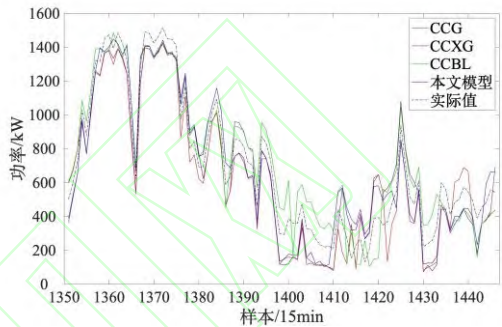
(a) #2 风机

(a) #2 wind turbine




(b) #13 风机

(b) #13 wind turbine



(c) #21 风机

(c) #21 wind turbine




(d) #23 风机


(d) #23 wind turbine

图 D4 不同风机预测对比


Fig.D4 Comparison of different wind turbine predictions



(a) 0.5h-ahead



(b) 1h-ahead



(c) 2h-ahead

图 D5 集群总功率预测对比

Fig.D5 Cluster total power prediction comparison



钟吴君

钟吴君 (1994), 男, 博士研究生, 主要从事新能源预测和负荷预测方面的研究工作, [395236969@qq.com](mailto:395236969@qq.com);